

Emne 1 Grundlæggende

Grundlæggende R



“Det er ikke, fordi noget er svært, at vi ikke tør, det er, fordi vi ikke tør, at noget er svært.” - Seneca

Inledning til kapitel

Først og fremmest, velkommen til kurset! Det her dokument er kursusnotaterne, som indeholder bla. videoer, forklaringer og problemstillinger, og vi opdaterer dem løbende gennem hele forløbet. Vær opmærksom på, at der også vil være flere dokumenter på Absalon vedrørende forelæsninger, workshops og løsninger til øvelserne.

I dette kapitel opsummerer vi nogle grundlæggende elementer inden for R og statistik, der betragtes som forudsætninger i dette kursus. Selvom vi i kurset skifter hurtigt over til tidyverse-pakken, som erstatter en stor del af funktionaliteten fra den såkaldte base-R, er det stadig vigtigt at have et grundlæggende kendskab til base-R. Hvis du har begrænset erfaring med base-R, anbefaler vi, at du bruger ekstra tid ud over de første mødegange for at nå det nødvendige niveau.

For at bestå kurset forventes det ikke, at du kender til alle detaljer og teorier bag de statistiske metoder, men at du kan anvende dem hensigtsmæssigt i praksis via R og fortolke resultaterne korrekte. Der vil være masser af muligheder for at øve dig i at anvende statistik hele vejen gennem kurset, og under eksamen vil vi ikke stille spørgsmål om metoder, der ikke er dækket i de forskellige øvelser (herunder workshop-opgaver). Lineær regression vil også blive gennemgået i forelæsningerne så vær ikke bekymret hvis du ikke har set det før.

Se gerne også “Quiz - Grundlæggende” på Absalon for at tjekke din forståelse og udfylde eventuelle huller i din viden (OBS! Quizen er tilgængelig kort tid inden kurset starter).

RStudio

Vi kommer til at være afhængig af RStudio til at arbejde med bla. R Markdown dokumenter. R Markdown er emnet i vores næste lektion og vi går igennem hele emnet så at alle er med uanset jeres mulige tidligere erfaringer.«

Det allerførste du burde gøre, hvis du ikke har installeret RStudio på din computer, er at downloade det gratis på nettet:

<https://www.rstudio.com/products/rstudio/download/#download>

Følg venligst RStudios egne anvisninger til at få det installeret. Bemærk, at installering af RStudio er ikke det samme som at have R installeret på din computer - man skal installere dem begge to og RStudio er afhængig af R men ikke omvendt.

De forskellige vinduer i RStudio

Du kan læse følgende for at få en overblik om de fire forskellige vinduer i RStudio:

<https://bookdown.org/ndphillips/YaRrr/the-four-rstudio-windows.html>

Her er et kort oversigt:

- Man skriver kode i **Source** (øverst til venstre)
- Man kører kode ved at tryk CMD+ENTER (eller WIN-KEY+ENTER)
- Koder køres ind i **Console** (som plejer at være nederst til venstre, selvom det er øverst til højre i billedet). Man kan også skrive koder direkte i Console, men det anbefales generelt ikke, når koden ikke bliver gemt.
- **Environment** - her kan man se blandt andet, alle objekter i Workspace.

Working directory

Når man arbejder på et projekt, er det ofte nyttigt at vide, den *working directory* som R arbejder i - det er den mappe, hvor R forsøger at åbne eller gemme filer, medmindre man angiver et andet sted.

```
getwd() #se nuværende working directory
list.dirs(path = ".", recursive = FALSE) #se alle mapper indenfor din working directory
setwd("~/Documents/") #angiv en ny working directory (C:/Users/myname/Documents hvis man bruger Windows)
```

Hvis man bruger Windows, skal man husk at skrive en path på følgende måde:

```
#notrun
setwd("C:/Users/myname/Documents") #enten med /
setwd("C:\\Users\\myname\\Documents") #eller med \\
```

OBS: vi som underiser bruger Mac/Linux, så hvis der er vigtige ting at huske for at bruge Windows, kan vi selvfølgelig også tilføje det her. Bemærk dog, at de allerfleste ting ved R programmering og tidyverse er ens uanset om man bruger Windows eller Mac.

R pakker

R pakker er i grund og bunden hver kun en samling af funktioner (eller datasæt i nogle tilfælde), der udvider, hvad er tilgængelige i base-R (den R man får, uden at indlæse en pakke). I R er der mange tusind R pakker (op mod 100,000), der er tilgængelige på **CRAN** (<https://cran.r-project.org/>). Inden for biologisk forskning er der også mange flere pakker på **Bioconductor** (<https://www.bioconductor.org/>), og i mange tilfælde kan R pakker også installeres direkte fra **Github**.

I dette kursus arbejder vi meget med en pakke der hedder **tidyverse**. **tidyverse** er i sig selv faktisk en samling af otte R pakker, som indlæses på en gang. Inden du indlæser pakken, skal du først sikre dig, at pakken er installeret på systemet ved følgende kommando:

Source Pane

Edit and run scripts (e.g. Rmarkdown templates), and view datasets

Environment Pane

Overview of objects (datasets, parameters, lists, etc.) you have imported or created.

Tip: Run script

Tip: Start new script

The screenshot displays the RStudio interface with four main panes. The Source Pane (top left) shows an R Markdown file titled 'cholera outbreak report' with a plot of age group (years) by sex (Male, Female, now/unspec). The Environment Pane (top right) shows the Global Environment with objects like lineist_clea, lineist_dict, lineist_raw, population_da, and values like first_week, LABS, obs_end, and obs_start. The R Console Pane (bottom left) shows the R commands run, including plot_age_pyramid, and an error message: 'Error: attempt to use zero-length variable name'. The Plots, Packages, and Help Pane (bottom right) shows the plot of age group (years) by sex (Male, Female, now/unspec) with cases (n) on the x-axis and age group (years) on the y-axis. The plot is a stacked bar chart with categories Confirmed (green), Probable (purple), and Suspected (orange).

Tip: Zoom and export plots

R Console Pane

R commands run are shown here, and non-graphic output and errors are displayed

Plots, Packages, and Help Pane

Commonly used to view graphics, install packages, and view help

Figure 1: Image source: <https://epirhandbook.com/en/r-basics.html>

```
install.packages("tidyverse")
```

Alle pakker på **CRAN** er installeret på samme måde. Når du faktisk gerne vil bruge en R pakke, skal du først indlæse den ved at bruge `library()`:

```
library(tidyverse)
```

Vi kommer til at arbejde med **tidyverse** pakker fra kapitel tre (vi starter med **ggplot2**), så det er en god idé at har **tidyverse** installeret allerede nu, fordi nogle gange kan det tage lang tid til at installere eller opdatere de mange andre mulige pakker, der **tidyverse** er afhængig af.

Vær opmærksom på, at der nogle gange opstår konflikter når det samme funktionnavn findes i flere pakker - for eksempel, funktionen `filter()` findes indenfor to forskellige pakker, nemlig **dplyr** og **stats**. Når du skriver `filter()` så ved R ikke, hvilken pakke du mener. I dette tilfælde kan du være mere konkret og skriver desuden pakkenavnen `dplyr::filter()` eller `stats::filter()` i stedet for bare `filter()`.

Det er god praksis at indlæse alle pakker du anvender i toppen / i begyndelsen af din script. På denne måde få man hurtigt overblik over, hvilke pakker er nødvendige for at få din kode til at fungere.

Hvor kommer vores data fra?

De forskellige datasæt vi kommer til at arbejde med i kurset stammer fra mange forskellige steder og er ikke nødvendigvis altid relateret til biologi.

Indbyggede datasæt

I R er der mange indbygget datasæt som er meget brugbart for at vise analyse- og programmeringskoncepter, hvilket gøre dem især populært til undervisning. Indbyggede datasæt er ofte tilgængeligt indenfor mange pakker, men `library(datasets)` er den hyppigst brugt (der er også mange indenfor `library(ggplot2)`). For eksempel, for at indlæse **iris**-datasættet, kan man bruge `data()`:

```
library(datasets)
data(iris)
```

Derefter er en *dataframe* med navnet **iris** tilgængelig og er også gemt som *objekt* i *workspacen* - se den "Environment" fane på højere side i RStudio, eller indtaste `ls()`, så burde du kunne se objektet. Man kan kun arbejde med objekter når de er en del af workspacen.

```
head(iris) #first few rows
```

##	Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
## 1	5.1	3.5	1.4	0.2	setosa
## 2	4.9	3.0	1.4	0.2	setosa
## 3	4.7	3.2	1.3	0.2	setosa
## 4	4.6	3.1	1.5	0.2	setosa
## 5	5.0	3.6	1.4	0.2	setosa
## 6	5.4	3.9	1.7	0.4	setosa

```
tail(iris) #last few rows
```

```
##      Sepal.Length Sepal.Width Petal.Length Petal.Width  Species
## 145          6.7          3.3          5.7          2.5 virginica
## 146          6.7          3.0          5.2          2.3 virginica
## 147          6.3          2.5          5.0          1.9 virginica
## 148          6.5          3.0          5.2          2.0 virginica
## 149          6.2          3.4          5.4          2.3 virginica
## 150          5.9          3.0          5.1          1.8 virginica
```

```
str(iris) #structure
```

```
## 'data.frame': 150 obs. of 5 variables:
## $ Sepal.Length: num 5.1 4.9 4.7 4.6 5 5.4 4.6 5 4.4 4.9 ...
## $ Sepal.Width : num 3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 2.9 3.1 ...
## $ Petal.Length: num 1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 1.4 1.5 ...
## $ Petal.Width : num 0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 0.2 0.1 ...
## $ Species : Factor w/ 3 levels "setosa","versicolor",...: 1 1 1 1 1 1 1 1 1 1 ...
```

```
summary(iris) #summary per column
```

```
##      Sepal.Length      Sepal.Width      Petal.Length      Petal.Width      Species
## Min.      :4.300    Min.      :2.000    Min.      :1.000    Min.      :0.100    setosa      :50
## 1st Qu.:5.100    1st Qu.:2.800    1st Qu.:1.600    1st Qu.:0.300    versicolor:50
## Median :5.800    Median :3.000    Median :4.350    Median :1.300    virginica  :50
## Mean      :5.843    Mean      :3.057    Mean      :3.758    Mean      :1.199
## 3rd Qu.:6.400    3rd Qu.:3.300    3rd Qu.:5.100    3rd Qu.:1.800
## Max.      :7.900    Max.      :4.400    Max.      :6.900    Max.      :2.500
```

Importeret af data fra .txt fil

Det er meget hyppigt, at man har sin data i formen af en .txt fil eller .xlsx fil på sin computer. En nem måde at åbne en .txt fil er ved at bruge `read.table()`, som i nedenstående:

```
data <- read.table("mydata.txt") #indlæs data filen mydata.txt som er i nuværende working directory
head(data)
```

Hvis datasættet i filen har kolonnenavne, skal man huske at bruge `header=T` for at undgå at den første række med kolonnenavne blive fortolket som data / observationer i stedet for kolonner.

```
data <- read.table("mydata.txt",header=T) #indlæs data filen mydata.txt som er i nuværende working directory
head(data)
```

Importeret af data fra Excel

Der findes også en hjælpsom pakke fra **tidyverset**, som hedder **readxl**, der kan indlæse Excel-ark direkte ind i R:

```
library(readxl)
data <- read_excel("data.xlsx")
data
```

Hvis man gerne vil referere til en bestemt ark, så kan man bruge en ekstra indstilling:

```
library(readxl)
data <- read_excel("data.xlsx", sheet = 1)
data
```

Kaggle

Hvis du kan lige at øve dig i statistik analyse (udover kurset), er Kaggle en fantastisk ressource til at finde forskellige datasæt. I rigtige mange tilfælde kan man også finde analyser some andre har lavet i R (eller f.eks. Python), hvilket kan være meget inspirerende.

Link hvis interesseret: <https://www.kaggle.com/>

Beregninger i R

Her er nogle helt grundlæggende koncepter når man arbejder med R. Du må selvfølgelig gerne springe sektionen over, hvis du allerede har meget erfaring med base-R. Men det kunne være godt at tjekke, om der noget du er ikke stødt på endnu. En god tilgang kunne være at arbejde gennem problemstillingerne nedenfor og bruger følgende notater som en reference.

Objekter

Man definere en objekt med brug af <- tegn

```
x <- 2 #x er defineret som 2
```

OBS! En objekts værdi kan nemt overskrives - vær opmærksomt på rækkefølgen af de udførte kommandoer:

```
x <- 2 #x er defineret som 2
x <- 4 #nu er x omdefineret som 4
```

Man kan også kombinere to objekter:

```
a <- 5 #a er defineret som 5
b <- a + x
b # 5 + 4
```

```
## [1] 9
```

Vær opmærksom på, at man kan ændre på **a**, uden at **b** ændre sig automatisk:

```
a <- 23
b #stadig 5 + 4
```

```
## [1] 9
```

Hvis man vil opdatere **b**, så skal den defineres igen:

```
b <- a + x
b # 23 + 4
```

```
## [1] 27
```

Vektorer

I R laver man en vektor med `c()`, hvor man adskiller de forskellige elementer med en komma, som i eksempel nedenfor:

```
a <- c(1,2,3,4,5) #sæt objektet 'a' til at være en vektor baseret af en talkæde
a
```

```
## [1] 1 2 3 4 5
```

Man er ikke begrænset til tal:

```
c <- c("cat","mouse","horse","sheep","dog")
c
```

```
## [1] "cat" "mouse" "horse" "sheep" "dog"
```

Datatyper

Når vi kommer til at arbejde med visualiseringer og data er det vigtigt at have styr på datatyper i vores datasættet. For eksempel har vektoren `c("cat","mouse","horse","sheep","dog")` ovenpå typen `character` (forkortet `chr`) og ikke `numeric` som `c(1,2,3,4,5)` (forkortet `num`):

```
is.numeric(c)
## [1] FALSE
is.character(c)
## [1] TRUE
```

Her er en list af de vigtigste datatyper:

Datatype	Navn	Beskrivelse
int	integer	kun hel tal <code>c(-1,0,1,2,3)</code>
lgl	logical	TRUE, TRUE, FALSE, TRUE, FALSE
chr	character	<code>c("Bob","Sally","Brian",...)</code>
fct	factor	bestemte niveauer e.g. Species: <code>c("setosa","versicola")</code>
dbl	double	Tal f.eks. <code>c(4.3902, 3.12, 4.5)</code>

Datatype	Navn	Beskrivelse
lst	list	forskellige data typer og specifikke elementer kombineret med <code>[[i]]</code> <code>[[1]] [1]</code> <code>c("red","blue") [[2]]</code> <code>[1] TRUE [[3]] [1]</code> <code>c(3,2.3,1.459)</code>

En datatype, der burde få særlig opmærksomhed er `fct` (factor). I følgende vektor `tea_coffee` har vi tekst, men blandt de fem elementer er der kun to forskellige niveauer (nemlig “tea” og “coffee”).

```
tea_coffee <- c("tea","tea","coffee","coffee","tea")
is.factor(tea_coffee)
## [1] FALSE
tea_coffee
## [1] "tea"      "tea"      "coffee" "coffee" "tea"
```

Vi vil derfor gerne fortælle R, at `tea_coffee` indeholder ikke kun tilfældig tekst men at der er en struktur bag indholdet. Derfor bruger vi funktionen `as.factor` for at lave vektoren om til datatypen `fct`.

```
tea_coffee <- as.factor(tea_coffee)
is.factor(tea_coffee)
## [1] TRUE
tea_coffee
## [1] tea      tea      coffee coffee tea
## Levels: coffee tea
```

De ‘ekstra’ oplysninger man har når en variabel er en factor bliver vigtigt når man arbejder med visualiseringer - f.eks. hvis vi gerne vil lave et barplot hvor man vil adskille søjlerne efter de to niveauer “tea” og “coffee” (visualiseringer er emnet af lektion 3).

Dataframes

<http://www.r-tutor.com/r-introduction/data-frame>

Mange af de ting, som vi laver i R tager udgangspunkt i dataframes (eller datarammer).

```
mydf <- data.frame("personID" = 1:5, "height" = c(140,187,154,132,165), "age" = c(34,31,25,43,29))
mydf
```

```
##   personID height age
## 1         1    140  34
## 2         2    187  31
## 3         3    154  25
## 4         4    132  43
## 5         5    165  29
```

Man kan få adgang til variabler i en dataframe via dollar tegn \$, f.eks. `personID` fra datarammen `mydf`:

```
mydf$personID
```

```
## [1] 1 2 3 4 5
```

Husk, at vores dataframe, ligesom et matrix (i R: `matrix()`) har to dimensioner - række og kolonner. Forskellen mellem en matrix og en dataramme er, at datarammer kan indeholde mange forskellige datatyper (herunder numeriske, faktorer, karakterer osv.), mens en matrix indeholder kun numeriske data. For eksempel, alle variabler i den ovenstående dataframe er numeriske, men vi kan godt tilføje en variabel som er ikke-numeriske:

```
mydf$colour <- c("red","blue","green","orange","purple") #make new variable which is non-numeric
mydf
```

```
##   personID height age colour
## 1         1    140  34     red
## 2         2    187  31     blue
## 3         3    154  25    green
## 4         4    132  43    orange
## 5         5    165  29    purple
```

Derefter er `mydf` en dataframe, der blander forskellige datatyper. Følgende objekt er til gengæld en matrix:

```
matrix(c(1, 2, 3, 4, 5, 6),
       nrow=3,
       ncol=2)
```

```
##      [,1] [,2]
## [1,]    1    4
## [2,]    2    5
## [3,]    3    6
```

Som beskrevet tidligere kan en matrix kun indeholde numeriske data før at gøre matematiske operationer mulig (matrix multiplikation osv.). Men, i dette kursus beskæftiger vi os primært med dataframes (som bliver kaldt for tibbles i **tidyverse**).

Delmængder af dataframes

Selvom vi kommer til at se på det igen når vi at arbejder med pakken **tidyverse**, er det vigtigt at forstå, hvordan man laver en delmængde i base-R. Det er et koncept som ofte skaber forvirring.

Når man vil gerne har en bestemt delmængde af en vector, bruger man firkantet parenteser `[ ]`. Følgende kode giver os de første to værdier fra vektoren `a`:

```
a[1:2]
```

```
## [1] 1 2
```

Bemærk, mens vektorer har kun en dimension, **har dataframes to dimensioner**. Når man skal lave en delmængde af en dataframe, skal man derfor fortælle R, hvilke rækker og hvilke kolonner skal være med.

```
mydf[indekser af rækker, indekser af kolonner] #kør ikke, kun beskrivende kode
```

For eksempel, hvis vi vil have de første to observationer af kun den anden variabel, skriver man følgende:

```
mydf[1:2, 2] #første to rækker (observationer), kun anden kolonne (variabel)
```

```
## [1] 140 187
```

Hvis vi vil beholde de første to observationer af alle variabler, kan den anden plads være tom:

```
mydf[1:2, ] #første to rækker, alle kolonner
```

```
##   personID height age colour
## 1         1    140  34    red
## 2         2    187  31    blue
```

Vi kan også angive et kolonnenavn direkte:

```
mydf[1:2, "height"]
```

```
## [1] 140 187
```

Man kan få en delmængde af rækkerne ved at:

```
mydf[mydf$height>=165,] #alle rækker i datarammen med height = 165 eller højere
```

```
##   personID height age colour
## 2         2    187  31    blue
## 5         5    165  29  purple
```

Her er en tabel af komparativer, som bliver gentaget når vi kommer til at lave delmængder i **tidyverse**:

Komparativ	Beskrivelse
<	mindre end / less than
>	større end / greater than
<=	mindre end eller lig med / less than or equal to
>=	større end eller lig med / greater than or equal to
==	lig med / equal to
!=	ikke lig med / not equal to
&	og / and
%in%	en del af / part of
	eller / or
!	ikke / not

Komparativen `%in%` er særlig brugbart og værd at huske:

```
mydf[mydf$personID %in% c(1,3,5),] #alle personer med personID 1,3 eller 5
```

```
## personID height age colour
## 1         1    140  34    red
## 3         3    154  25  green
## 5         5    165  29  purple
```

Her er et eksempel, hvordan man bruger udråbstegnet: personer med personID, der ikke er 1,3 eller 5:

```
mydf[!(mydf$personID %in% c(1,3,5)),] #alle personer med personID 2 eller 4
```

```
## personID height age colour
## 2         2    187  31    blue
## 4         4    132  43  orange
```

If/else

If/else kodekonstruktioner er til at udføre forskellige handlinger baseret på om en bestemt betingelse er opfyldt. For eksempel, if med betingelsen `number > 0`:

```
number <- 42
if (number > 0) {
  print("Number is positive")
}
```

```
## [1] "Number is positive"
```

Hvis betingelsen er sand, udføres den handling indenfor { }, dvs. “Number is positive” printes.

If/else konstruktioner gør det samme, men hvis betingelsen er ikke opfyldt, udføres en alternativ handling:

```
number <- -5
if (number > 0) {
  print("Number is positive")
} else {
  print("Number is not positive")
}
```

```
## [1] "Number is not positive"
```

Man kan også opnå samme resultatet med at bruge den alternative funktion `ifelse`:

```
number <- 3
numbers_of_interest <- c(1,3,5,7)
ifelse(test = number %in% numbers_of_interest,
       yes = "Number is interesting",
       no = "Number is uninteresting")
```

```
## [1] "Number is interesting"
```

Man behøver ikke at skrive ordene “test”, “yes” og “no” hver gang, så længe man bruger rækkefølgen af argumenterne lige som funktionen forventer:

```
ifelse(number %in% numbers_of_interest,
       "Number is interesting",
       "Number is uninteresting")
```

```
## [1] "Number is interesting"
```

Loops

I base-R kan man laver simple loops (løkke) med følgende konstruktion:

```
for (i in 1:5) {
  print(i)
}
```

```
## [1] 1
## [1] 2
## [1] 3
## [1] 4
## [1] 5
```

Loops bliver et stort emne senere i kurset (under emnet 8/9).

Descriptive statistics / beskrivende statistik

Simulere data fra den normalfordeling

Hvis du har brug for at vide mere om den normalfordeling: <http://www.r-tutor.com/elementary-statistics/probability-distributions/normal-distribution>

Man kan nemt lave sin egne 'fake' data ved at simulere det fra en fordeling, der typisk er normalfordelingen, da den er den mest almindelige fordeling i den virkelige verden (husk den klassiske klokkeform). I R kan man anvender funktionen `rnorm` til at simulere data. Først angiver man antallet af observationer, og derefter den gennemsnitlige værdi og standardafvigelsen (sd), som er de to nødvendige parametre for at beskrive en normalfordeling.

```
x <- rnorm(25, mean = 0, sd = 1) #standard normalfordeling
x #så har vi 25 værdier fra en normal distribution med mean = 0 og standard deviation = 1
```

```
## [1] 1.85748967 -0.75153697 -0.04803268 1.32024753 0.08168649 0.08647694 2.25070833 -0.57996136
## [12] -1.31004684 -0.44770058 0.62066604 0.45488011 2.13657167 1.15934931 -0.87281583 0.25738674
## [23] 0.16064802 -0.84434530 1.59470000
```

I stedet for at kigge på alle værdier på én gang, vil vi måske kun kigge på de første (eller sidste) værdier:

```
head(x) #første 6
## [1] 1.85748967 -0.75153697 -0.04803268 1.32024753 0.08168649 0.08647694
tail(x) #sidste 6
## [1] 0.1020194 0.4961167 0.5778173 0.1606480 -0.8443453 1.5947000
x[1] #første værdi
## [1] 1.85749
x[length(x)] #sidste data point
## [1] 1.5947
```

Bemærk, at i modsætning til Python og mange andre programmeringssprog, bruger R en '1'-baseret indeksering. Det betyder, at den første værdi er `x[1]` og ikke `x[0]` som i Python.

Measures of central tendency

Funktion	Beskrivelse
<code>mean()</code>	aritmetisk gennemsnit / arithmetic mean $\bar{x}_i = \frac{1}{n} \sum_{i=1}^n x_i$
<code>median()</code>	median værdi / median value
<code>max()</code>	maksimum værdi / maximum value
<code>min()</code>	minimum værdi / minimum value
<code>var()</code>	varians / variance $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_i)^2$
<code>sd()</code>	standardafvigelsen / standard deviation s

Lad os afprøve dem på vores simulerede data:

```
my_mean <- mean(x)
my_median <- median(x)
my_max <- max(x)
my_min <- min(x)
my_var <- var(x)
my_sd <- sd(x)
c(my_mean,my_median,my_max,my_min,my_var,my_sd) #print results
```

```
## [1] 0.3496839 0.1606480 2.2507083 -1.3100468 0.8926632 0.9448085
```

Man kan også lave et summary af dataen, som består af mange af de statistiker navnt ovenpå:

```
summary(x)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
## -1.31005 -0.08087  0.16065  0.34968  0.62067  2.25071
```

tapply()

`tapply()` er en meget nyttig funktion i R, som kan bruges til at anvende en funktion på en gruppe af data baseret på værdier i en anden vektor. Funktionen tager tre hovedargumenter: den vektor, som vi ønsker at anvende funktionen på, den vektor, som bruges til at gruppere dataene, og funktionen, som vi ønsker at anvende på hver gruppe. `tapply()` opdeler dataene i grupper baseret på den anden vektor og anvender funktionen på hver gruppe.

Resultatet af `tapply()` vil være en vektor, som indeholder resultaterne af funktionen anvendt på hver gruppe af data. For eksempel:

```
data(iris)
tapply(iris$Sepal.Length,iris$Species,mean) # alle argumenter i kun en linje
```

```
##      setosa versicolor  virginica
##      5.006      5.936      6.588
```

Vi tog en vektor med navn Sepal.Length, opdeler den efter Species og beregner gennemsnittet ved hjælp af funktionen mean for hver af de tre arter i variabelen Species (dvs. setosa, versicolor og virginica). Alternativt kunne man have beregnet gennemsnittet for hver af de tre Species separat (en tilgang, der ikke skalerer godt!):

```
# gennemsnit Sepal Length for Species setosa
mean_setosa <- mean(iris$Sepal.Length[iris$Species=="setosa"])

# gennemsnit Sepal Length for Species versicolor
mean_versi <- mean(iris$Sepal.Length[iris$Species=="versicolor"])

# gennemsnit Sepal Length for Species virginica
mean_virgin <- mean(iris$Sepal.Length[iris$Species=="virginica"])

c(mean_setosa,mean_versi,mean_virgin)

## [1] 5.006 5.936 6.588
```

Det er også værd at kende tapply-koncepten, fordi vi kommer til lære et alternativ i tidyverse (dvs. group_by og summarise).

Statistiske tester

Her er en oversigt over nogle af de mest grundlæggende tests, som man kan udføre på data i R. Vi går i dybden med teorien bag disse tests (vi håber at du har lært det tidligere), men vi forventer, at du er i stand til at anvende dem korrekt i R og fortolke resultaterne. Hvis du ikke er bekendt med nogle af disse tests, vil der være masser af muligheder for at øve dig i statistik gennem kurset.

- t-test: Bruges til at sammenligne to grupper og afgøre, om forskellen mellem deres gennemsnitlige værdier er statistisk signifikant.
- ANOVA: Bruges til at sammenligne mere end to grupper og afgøre, om der er statistisk signifikant forskel mellem mindst to af grupperne.
- Korrelationsanalyse: Bruges til at afgøre, om der er en statistisk signifikant sammenhæng mellem to variabler.
- Regressionsanalyse: Bruges til at afgøre, om der er en statistisk signifikant sammenhæng mellem en uafhængig variabel og en afhængig variabel. Man forudsiger værdien af den afhængige variabel baseret på værdien af den uafhængige variabel.
- Chi-square test: Bruges til at afgøre, om der er en statistisk signifikant forskel mellem observerede og forventede værdier for kategoriske variabler.

P-værdien

Først og fremmest er det vigtigt at kunne huske p-værdi både i forhold til definitionen og i forhold til hvordan det fortolkes.

P-værdien er sandsynligheden for at observere et resultat lige så ekstremt eller mere ekstremt end det observerede, givet at null-hypotesen er sand. Null-hypotesen er en antagelse om, at der er ikke en signifikant forskel mellem grupper eller variabler i det dataset, som der arbejdes med.

Hvis p-værdien er mindre end det valgte signifikansniveau (typisk 0,05), så betyder det, at det observerede resultat er usandsynligt at opstå ved ren tilfældighed, og null-hypotesen er afvist til fordel for den alternative hypotese om, at der er en signifikant forskel mellem grupper eller variabler i datasættet.

Korrelation

Korrelation måler styrken og retningen af den lineære sammenhæng mellem to kontinuerte variabler, som begge er normalfordelte:

- > 0 betyder, at der er en positiv sammenhæng
- < 0 betyder, at der er en negativ sammenhæng
- $= 0$ betyder, at der er ingen sammenhæng mellem de to variabler

```
data(cars)
cor(cars$speed, cars$dist)
```

```
## [1] 0.8068949
```

Husk dog, at “Correlation does not equal causation” - dvs. at korrelation er bare en sammenhæng og ikke nødvendigvis angiver en årsagssammenhæng mellem to variabler.

Funktionen `cor.test()` kan bruges til at teste, om korrelationen mellem to variabler er statistisk signifikant. Null-hypotesen antager, at der ikke er nogen korrelation mellem de to variabler i den population som er repræsenteret i datasættet.

```
cor.test(cars$speed, cars$dist)
```

```
##
## Pearson's product-moment correlation
##
## data: cars$speed and cars$dist
## t = 9.464, df = 48, p-value = 1.49e-12
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## 0.6816422 0.8862036
## sample estimates:
## cor
## 0.8068949
```

Her er p-værdien 0 mindre end 0.05. Derfor konkluderer man, at der er en signifikant sammenhæng mellem de to variabler.

Test for uafhængighed (chi-sq test)

En chi-squared test kan bruges til at undersøge, om der er en statistisk signifikant sammenhæng mellem antallet af observationer i to eller flere forskellige kategorier. For eksempel kan man teste for sammenhængen mellem antallet af kopier af en genvariant og to forskellige farver på blomster i en bestemt planteart.

	0	1	2
red	29	31	16
pink	11	16	24

Vi vil gerne vide om phenotypen er afhængig af genotypen:

- H_0 : antallet af genkopier og phenotypen er uafhængig af hinanden vs
- H_1 : antallet af genkopier og phenotypen er afhængig af hinanden

Testen antager at man beregner forventede værdier under nulhypotesen som siger at der er ingen sammenhæng mellem de to kategorier. Derefter sammenligner testen disse forventede værdier med de faktiske, observerede værdier. Man laver testen i R ved at benytte funktionen `chisq.test()`:

```
chisq.test(dat)
```

```
##
## Pearson's Chi-squared test
##
## data:  dat
## X-squared = 9.9516, df = 2, p-value = 0.006903
```

P-værdien er 0.006903 og mindre end 0.05. Derfor afviser vi nulhypotesen og konkluderer, at der er en signifikant sammenhæng mellem de to variabler. Dette er i overensstemmelse med vores intuition som siger at der er flere røde blomster uden genkopi (0) sammenlignet med røde blomster med to genkopier (2). Det modsatte er sandt for de lyserøde blomster.

1 sample t-test

For at vise en 1-sample t-test, simulerer vi data fra en normalfordeling med middelværdi af 3 ved hjælp af `rnorm()`-funktionen:

```
set.seed(290223) # bare for at få den samme resultat hver gang
x <- rnorm(10,mean = 3,sd = 1)
```

Forestil dig, at du ikke helt stoler på funktionen `rnorm()` og ønsker at teste, om `x` stammer fra en normalfordeling med en middelværdi af 3. Nulhypotesen og den alternative hypotese (to-sidet test) er derfor:

- $H_0 : \mu = 3$, VS
- $H_1 : \mu \neq 3$

For at lave testen i R, bruger man funktionen `t.test()` og angiver `mu = 3` for at definere vores hypoteser:

```
t.test(x,mu = 3)
```

```
##
## One Sample t-test
##
## data:  x
## t = -1.1448, df = 9, p-value = 0.2818
## alternative hypothesis: true mean is not equal to 3
## 95 percent confidence interval:
##  2.169968 3.272231
## sample estimates:
## mean of x
##  2.721099
```

Fra resultatet kan man se, at p-værdien er estimeret til 0.2818, og da den er større end 0.05 kan vi ikke afvise nulhypotesen. Derfor kan vi konkludere at middelværdien af x ikke adskiller sig signifikant fra 3.

Bemærkning: da vi simulerede vores data fra en normalfordeling med en middelværdi af tre, vidste vi i forvejen at det korrekte svar er, at acceptere nulhypotesen. Hvis vi ville have afvist nulhypotesen, ville vi have lavet en **type I fejl** - dvs. at vi afviser nulhypotesen når det faktisk er sandt.

2-sample t-test

Undersøger om der er en forskel mellem middelværdierne af to grupper - er disse grupper afledt af den samme normalfordeling? Hypoteserne er således (to-sidet):

- $H_0 : \mu_1 = \mu_2$, VS
- $H_1 : \mu_1 \neq \mu_2$

I følgende kode simulere vi to stikprøver, der kommer fra en normalfordeling med forskellige middelværdier og bruger funktionen `t.test`. Man kan definere at de to stikprøver har samme varians ved `var.equal = T` indenfor funktionen `t.test`:

```
x <- rnorm(10,3,1)
y <- rnorm(10,5,1)

t.test(x,y,var.equal = T)

##
## Two Sample t-test
##
## data: x and y
## t = -5.4258, df = 18, p-value = 3.729e-05
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -2.700858 -1.193081
## sample estimates:
## mean of x mean of y
## 2.783056 4.730025
```

Hvis man til gengæld ikke kan antage, at variansen er den samme i de to grupper:

```
x <- rnorm(10, 3, 1)
y <- rnorm(10, 5, 3) #større variance

t.test(x,y,var.equal = F) #var.equal=F er 'default' så man behøver ikke at specificere

##
## Welch Two Sample t-test
##
## data: x and y
## t = -2.0238, df = 11.77, p-value = 0.0663
## alternative hypothesis: true difference in means is not equal to 0
## 95 percent confidence interval:
## -3.9077927 0.1483728
## sample estimates:
## mean of x mean of y
## 2.757436 4.637146
```

Bemærk at hvis man kan antage at variansen er den samme, så har man mere **power** (kræft) til at opdage en virkelig forskel (dvs. få en signifikant forskel som resultat af testen).

Paired t-test / parret t-test

En parret t-test anvender man f.eks. når man har målinger af den samme population af personer i hver stikprøve, og man gerne vil teste om forskellen i værdier mellem de to stikprøver er signifikant. For eksempel hvis vi har “før” og “efter” målinger af de samme 10 personer:

```
set.seed(320)
before <- rnorm(10, 3, 1)
after <- rnorm(10, 6, 2)

t.test(before, after, paired = T) # definere parret data

##
## Paired t-test
##
## data: before and after
## t = -9.3296, df = 9, p-value = 6.356e-06
## alternative hypothesis: true mean difference is not equal to 0
## 95 percent confidence interval:
## -5.415186 -3.301613
## sample estimates:
## mean difference
## -4.358399

t.test(before - after, mu = 0) # exactly the same result

##
## One Sample t-test
##
## data: before - after
## t = -9.3296, df = 9, p-value = 6.356e-06
## alternative hypothesis: true mean is not equal to 0
## 95 percent confidence interval:
## -5.415186 -3.301613
## sample estimates:
## mean of x
## -4.358399
```

ANOVA (variansanalyse)

Har man flere grupper i stedet for to, kan man bruge ANOVA (analysis of variance eller variansanalyse). Har man en kategorisk variabel med k grupper, er nul/alternativhypotesen:

- $H_0 : \mu_1 = \mu_2 = \dots = \mu_k$
- H_1 : ikke alle middelværdier er ens

```
#simulere data til 3 forskellige grupper fra den normalfordeling med standardafvigelse af 3
group1 <- rnorm(50, 10, 3)
group2 <- rnorm(55, 10, 3)
group3 <- rnorm(48, 5, 3)

#data må være i en dataramme, med vores værdier i den ene kolonne og grupperne i den anden kolonne
y <- c(group1, group2, group3)
x <- c(rep("G1",50), rep("G2",55), rep("G3",48))
mydf <- data.frame("group" = x, "value" = y)
```

For at udføre testen kan man anvende funktionen `lm()`, som står for “linear model” og kan bruges til at opbygge forskellige modeller. Her definerer vi en model, hvor hver gruppe (G1, G2 og G3 fra variabelen `x`) har sin egen middelværdi. Forskellen mellem disse middelværdier udgør definitionen af vores alternativhypotesen:

```
mylm <- lm(value ~ group, data = mydf) #H1 model
```

Under nulhypotesen til gengæld har alle grupper den samme middelværdi, og derfor behøver vi ikke at inkludere variabelen `group` i modellen. Vi definerer det i modellen ved at skrive 1, som betyder, at forventede værdier for den afhængige variabel `value` blot er dens middelværdi:

```
mylm_null <- lm(value ~ 1, data = mydf) #H0 model
```

For at sammenligne de to modeller benytter vi funktionen `anova()` (efter analysis of variance):

```
anova(mylm_null, mylm)
```

```
## Analysis of Variance Table
##
## Model 1: value ~ 1
## Model 2: value ~ group
##   Res.Df    RSS Df Sum of Sq    F    Pr(>F)
## 1     152 2215.4
## 2     150 1509.9  2     705.55 35.047 3.245e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

P-værdien er (<0.05). Nulhypotesen er afvist til fordel for alternativhypotesen, altså modellen, hvor hver gruppe har sin egen middelværdi. OBS! Det er på trods af, at to af tre grupper kommer fra en normalfordeling med præcis de samme middelværdier. Faktisk er det nok at den tredje gruppe har en anden middelværdi.


Lineær regression / linear regression

OBS! Se også venligst videon vedrørende R Markdown (næste emne), hvor Sarah arbejder igennem lineær regression med R.

Formålet af en lineær regression er at måle (en retningsbestemt) relation mellem to kontinuerte variabler. I simpel lineær regression svarer det til, at man vil finde den rette linje gennem punkterne, der bedst beskriver relationen.

Som en eksempel anvender vi datasættet `mtcars` og definere den afhængige (response) variabel via `mpg` og den uafhængige (predictor) variabel som `wt`.

Best fit line for predicting mpg from weight



Som beskrevet tidligere, skriver vi relationer i R som f.eks. `mpg ~ wt` og benytter `lm()` (`lm(mpg~wt,data=mtcars)`):

```
mylm <- lm(mpg ~ wt, data = mtcars) # opbyg en lineær regressions model
mylm
```

```
##
## Call:
## lm(formula = mpg ~ wt, data = mtcars)
##
## Coefficients:
## (Intercept)      wt
##      37.285     -5.344
```

Vores koefficienter / coefficients beskriver den bedste rette linje:

- Skæringen (intercept): 37.285
- Hældningskoefficient (slope): -5.344

Det betyder, at hvis vægten `wt` af en bil stiger med 1, så stiger `mpg` ved -5.344 (det vil sige at `mpg` reduceres med 5.344).

R-squared bestemmelseskoefficient / coefficient of determination

R^2 eller “forklaringsgraden” (bestemmelseskoefficient) har til formål at forklare, hvor godt vores lineære model passer til de data. For eksempel hvor meget af variansen i `mpg` forklares af variabelen `wt`?

- Hvis det er tæt på 1 - så er der en meget tæt relation (hvis man kender vægten, så vide man også mpg med stor sikkerhed).
- Hvis det er tæt på 0 - så er relationen svag - sandsynligheden er høj at der er andre variabler der bedre forklarer variansen i mpg.

I ovenstående model, kan man se R^2 værdien med `summary(mylm)`.

```
summary(mylm)
```

```
##
## Call:
## lm(formula = mpg ~ wt, data = mtcars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.5432 -2.3647 -0.1252  1.4096  6.8727
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  37.2851     1.8776  19.858 < 2e-16 ***
## wt          -5.3445     0.5591  -9.559 1.29e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 3.046 on 30 degrees of freedom
## Multiple R-squared:  0.7528, Adjusted R-squared:  0.7446
## F-statistic: 91.38 on 1 and 30 DF,  p-value: 1.294e-10
```


Det fortæller os, at $R^2 = 0.7528$.

Antagelser ved brug af lineær regression

- Normalfordelte residualer
- Residualer har samme spredning (varianshomogenitet)
- Uafhængighed
- Fit er linæer


Koden `plot(mylm, which=c(1))` beskriver residualer vs forudsagte (fitted) værdier - de skal være tilfældigt fordelt over plottet og prikkernes varians skal være nogenlunde konstant langt x-aksen (dette afspejles i den flade forløb af den røde linje).

```
plot(mylm, which = c(1))
```



Med koden `plot(mylm, which = c(2))` kan man tjekke antagelsen af en normalfordeling. Punkterne skal være nogenlunde tæt på den diagonale linje.

```
plot(mylm, which = c(2))
```



Multiple lineær regression

Her kan man tilføje flere variabler til formelen af vores model.

```
mylm_disp <- lm(mpg ~ wt + disp, data = mtcars) # opbyg en lineær regressions model
summary(mylm_disp)
```

```
##
## Call:
## lm(formula = mpg ~ wt + disp, data = mtcars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3.4087 -2.3243 -0.7683  1.7721  6.3484
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  34.96055    2.16454   16.151 4.91e-16 ***
## wt           -3.35082    1.16413   -2.878  0.00743 **
## disp         -0.01773    0.00919   -1.929  0.06362 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.917 on 29 degrees of freedom
## Multiple R-squared:  0.7809, Adjusted R-squared:  0.7658
```

```
## F-statistic: 51.69 on 2 and 29 DF,  p-value: 2.744e-10
```

Her kan man se, at med tilføjelsen af variabelen `disp`, er R^2 steget til 0.7809. Bemærk, at jo flere variabler man tilføjer til modellen, jo større bliver R^2 -værdien. Den modificeret R^2 værdi er lavere fordi den prøver at tage højde for kompleksiteten af modellen (mængden af parametre der er).

Variablen `disp` er faktisk ikke selv signifikant når der er taget højde for variabelen `wt` (p-værdien 0.0636 - tjek, at du selv kan finde værdien i resultatet).

Hvis en af de uafhængige variabler er kategorisk, bruger man funktionen `anova` til at teste effekten af den variabel. For eksempel har variabelen `cyl` 3 mulige værdier (niveauer) - 4, 6 og 8. Vi kan tage op variabelen i vores model:

```
mylm_cyl <- lm(mpg ~ wt + factor(cyl), data = mtcars)
summary(mylm_cyl)
```

```
##
## Call:
## lm(formula = mpg ~ wt + factor(cyl), data = mtcars)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -4.5890 -1.2357 -0.5159  1.3845  5.7915
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   33.9908     1.8878  18.006 < 2e-16 ***
## wt           -3.2056     0.7539  -4.252 0.000213 ***
## factor(cyl)6  -4.2556     1.3861  -3.070 0.004718 **
## factor(cyl)8  -6.0709     1.6523  -3.674 0.000999 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 2.557 on 28 degrees of freedom
## Multiple R-squared:  0.8374, Adjusted R-squared:  0.82
## F-statistic: 48.08 on 3 and 28 DF,  p-value: 3.594e-11
```

Man kan ikke se effekten af `cyl` i den ovenstående `summary` men man kan teste den med `anova`:

```
anova(mylm,mylm_cyl)
```

```
## Analysis of Variance Table
##
## Model 1: mpg ~ wt
## Model 2: mpg ~ wt + factor(cyl)
##   Res.Df  RSS Df Sum of Sq    F    Pr(>F)
## 1      30 278.32
## 2      28 183.06  2    95.263 7.2856 0.002835 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Så kan man se, at `cyl` er signifikant.

Problemstillinger

Husk quizen på Absalon, og lav gerne nedenstående øvelser for at øve dine færdigheder i R:

- Øvelser 2-8 er meget grundlæggende og kan godt springes over, hvis man er nogenlunde fortrolig med base-R.
- Vi vil anbefale øvelser 9-15 til alle som en god måde at teste jeres viden.
- Øvelser 16-20 fokuserer på andre statistiske tests i R. Vi kommer tilbage til regression flere gange i kurset, så det vil være en god idé at have kendskab til funktionen `lm()` til at opbygge modeller i ANOVA / simpel lineær regression (se også videoen og problemstillingerne knyttet til det næste emne, R Markdown).

Quiz - Basics

1) Lav venligst quizen på Absalon som hedder “Quiz - Grundlæggende”.

Grundlæggende R

2) (helt grundlæggende viden)

Åbn en ny fil i RStudio ved at klikke på “File” > “New File” > “R Script”. Kør følgende kode en linje ad gangen og tjek, om du forstår outputtet.

Husk, at den nemmeste måde at køre kode på er ved at trykke på CMD+ENTER (Mac) eller WIN-KEY+ENTER (Windows).

```
2+2
2*2
x <- 4
x <- x+2
sqrt(x)
sqrt(x)^2
rnorm(10, 2, 2)
log10(100)
y <- c(1, 4, 6, 4, 3)
class(y)
class(c("a", "b", "c"))
mean(y)
sd(y)
seq(1, 13, by = 3)
```

```
c(1,2,3,4) > 2 #giver bare TRUE eller FALSE
ifelse(c(1,2,3,4) > 2, "yes", "no") #omsætte TRUE eller FALSE til "yes" eller "no"
ifelse(c(1,2,3,4) >= 2, "yes", "no") #se forskellen
c(1,2,3,4) == 2 #logic
c(1,2,3,4) != 2 #logic
```

3) (helt grundlæggende viden)

Kør følgende kode for at åbne nogle af de indbyggede datasæt, som vi også kommer til at bruge i kurset.

- Prøve `head()`, `nrow()`, `summary()` osv.
- Prøve også f.eks. `?cars` for at se en beskrivelse.

```
data(iris)
data(cars)
data(ToothGrowth)
data(sleep)
head(chickwts)
data(trees)
#se her for andre:
library(help = "datasets")
```

4) (grundlæggende plots)

Vi viser eksempler for at plotte datasættet “iris”. Prøv også at plotte data af andre indbyggede datasæt, som du har indlæst.

```
plot(iris$Sepal.Length,iris$Sepal.Width)
hist(iris$Sepal.Width)
boxplot(iris$Sepal.Length~iris$Species)
```

Du kan også gøre plottene mere informativ ved at give dem en titel og navne på akserne. Prøv at finde dokumentationen for plot() ved at skrive ?plot i R-konsollen. Du kan tilføje ylab, xlab og main (titel) i én af plottene. Prøv også at eksperimentere med farver ved at bruge col. Bemærk dog, at vi vil skifte måden at lave plottene, når vi begynder at bruge ggplot2.

5) (dataframes)

Brug datasættet cars (data(cars)) til at:

- Lav et scatter plot med speed på x-aksen og dist på y-aksen.
- Tilføj en ny kolonne med følgende kode:

```
cars$fast <- cars$speed > 15
```

- Brug mean på den nye kolonne fast for at finde ud af andelen af biler, der er hurtige end 15.
- Brug ifelse så at du får fast eller slow i din nye kolonne i stedet for TRUE/FALSE.
- Beregn gennemsnitsværdien af variablen dist for fast biler og slow biler hver for sig (brug funktionen tapply). Gem resultatet med <-.
- Brug barplot til at lave et plot af den gennemsnitlige dist for fast biler og slow biler.

6) (dataframes)

En dataframe kan indeholde forskellige datatyper (i modsætning til en matrix). Lav en ny dataframe (med funktionen data.frame()) med tre kolonner, som hedder navn, alder og yndlings_farve (vælg værdierne selv). Sørg for, at din dataframe har 4 rækker.

```
mydf <- data.frame("navn"= c("alice","freddy", ... ), "alder" = c(...), ...) # OBS! Tilpasse venligst o
dim(mydf) # fire rækker og tre kolonner
mydf
```

7) (dataframes)

- Tilføj en ny kolonne random til din egen dataframe - hvor værdierne kommer fra en normalfordeling med en middelværdi af 5 og standardafvigelsen af 1 (brug venligst funktionen rnorm()).

```
mydf$random <- # skriv her
```

- Tilføj endnu en kolonne, `lucky_number`, til din dataframe ved at bruge funktionen `sample()` for at tilføje et tilfældigt tal mellem 1 og 4 (prøv også `replace=TRUE` og `replace=FALSE` og forstå forskellen)

8) (delmængder af dataframes)

Åbn datasættet “ToothGrowth” med følgende kode:

```
data("ToothGrowth")  
?ToothGrowth
```

- Find delmængden af datasættet så at `diet` (variablen `supp`) er “OJ” og længden (variablen `len`) er større end 15.

```
newdf <- ToothGrowth[#skriv venligst her og lave delmængden af observationerne,]
```

- Hvor mange rækker er der i den nye dataramme `newdf`?
- Hvor mange unikke værdier er der i variabelen `dose` (brug funktionen `unique`) ?
- Find delmængden af datasættet `ToothGrowth`, hvor variabelen `dose` er 0.5 eller 2.0 (hint: brug `%in%` eller `|`) og `supp` er “VC”.
- Beregn den gennemsnitlige længde for observationerne i delmængden.

Kort analyse med reaktionstider

9) (indlæse data)

Åbn filen “reactions.txt” (se Absalon) ved at bruge funktionen `read.table()` og gem resultatet i variabelen `data`. Husk at tjekke, om filen indeholder variabelnavne og brug `header=T` hvis nødvendigt.

```
data <- # skriv her
```

10) (faktor variabler)

Variablerne `subject` og `time` blev indlæst som henholdsvis `int` (heltal) og `chr` (character) datatyper, men de skal i stedet være `factor` variabler. Brug funktionen `as.factor()` til at ændre dem til at være `factor` variabler.

```
#gør subject til en faktor  
data$subject <- as.factor(data$subject)  
  
## gør den samme her for time:
```

- Hvor mange niveauer er der i hver af de to variabler efter ændringen til faktorvariabler? Prøv funktionerne `levels()` eller `nlevels()`.

11) (delmængder af dataframes)

Lav to delmængder af det ovenstående datasæt ved at:

- Oprette en delmængde til alle observationer fra tidspunktet “før” ved at vælge rækkerne i dataframen hvor `data$time == “before”`.
- Oprette en delmængde til alle observationer fra tidspunktet “efter”.

```
RT_before <- data[ # skriv her , ]  
RT_after <- # skriv her
```

- Opret endnu en delmængde, som viser alle observationer fra tidspunktet “før” med en reaktionstid på mindst 800.
- Hvor mange personer er der i denne delmængde?

```
RT_before_mindst800 <- # skriv her
```

12) (mean og tapply)

Benyt funktionen `mean()` til at beregne den gennemsnitlige reaktionstid (variablen RT) for “before”- og “after”-delmængderne.

- Brug funktionen `tapply()` på det oprindelige datasæt `data` for at beregne den samme middelværdi med mindre kode.

```
tapply(#skriv her,#skriv her,#skriv her)
```

- Er reaktionstiderne blevet hurtigere eller langsommere i gennemsnit?

13) (beregns forskellen og gennemsnittet)

Bemærk, at datasættet er ‘paired’ - målingerne er fra de samme personer både “before” og “after”.

- Opret en vektor `diff`, der indeholder forskellene i reaktionstiderne mellem “before” og “after” for hver person.
- Beregn venligst den gennemsnitlige forskel i reaktionstiderne.

```
diff <- # ændringen i reaktionstiden mellem "before" and "after"  
mean(diff)
```

- Tjek, om tegnet på middelværdien stemmer overens med din konklusion fra 11) - hvis den er positiv, betyder det, at reaktionstiderne er blevet langsommere.

14) (lav t-test i R)

Lav en t-test (funktionen `t.test()`) for at teste hypotesen om, at den gennemsnitlige forskel i reaktionstiderne mellem “before” og “after” er forskellige fra 0.

```
t.test(#skriv her...)
```

Find følgende i outputtet fra R:

- Hvor er test-statistiken `t`?
- Hvor er p-værdien?
- Hvad er alternativhypotesen?

Husk at skrive en kort sætning med dine endelige konklusioner.

Øvelse med CO2

15) (t-test med CO2)

- Indlæs datasættet med kommandoen `data(CO2)`.
- Opret en delmængde med kun observationer af “Quebec” (variablen `Type`).
- Beregn den gennemsnitlige optagelse (variablen `uptake`) for hvert behandlingstype (variablen `Treatment`) i din delmængde ved hjælp af `tapply()`-funktionen.
- Udfør en t-test ved hjælp af `t.test()`-funktionen for at sammenligne optagelsen mellem de to behandlinger i din delmængde.
- Skriv en kort sætning med din konklusion.

Ekstra øvelser med andre statistiske tests

16) (Chi-squared)

Kør følgende kode til at få en tabel (selve koden er ikke vigtig):

```
mytable <- structure(
  c(80L, 97L, 372L, 136L, 87L, 119L),
  .Dim = 3:2,
  .Dimnames = structure(
    list(
      c("First", "Second", "Third"),
      c("Died", "Survived")
    ),
    .Names = c("Class", "Survival")
  ),
  class = "table"
)

mytable
```

```
##           Survival
## Class    Died Survived
##  First     80      136
##  Second    97       87
##  Third   372     119
```

Tabellen beskriver antallet af passagerer ombord skibet ‘Titanic’, som sank den 15. april 1912 efter et sammenstød med et isbjerg 600 km sydøst for Halifax, Nova Scotia i Canada. Tabellen er opdelt i tre klasser (første-, anden-, tredje klasse) og viser antallet af passagerer, som overlevede tragedien og antallet af passagerer, som desværre omkom.

- Benyt funktionen `chisq.test()` på tabellen.
- Hvad er nulhypotesen til denne test?
- Er testen signifikant?
- Er passagerenes klasse og deres chance for at overleve uafhængige af hinanden?
- Hvilken af de tre klasser havde den bedste chance for at overleve?

Vi kommer til at arbejde meget mere med datasættet `Titanic` i emnet Tidyverse - dag 1!

17) (Korrelationsanalyse)

Åbn datasættet `trees` og lav et spredningsplot / scatter plot med variabelen `Girth` på x-aksen og variabelen `Volume` på y-aksen.

```
data(trees)
summary(trees)
```

- Anvend funktionen `cor.test` for at teste, om der er en signifikant korrelation mellem de to variabler. Brug `method = "pearson"` (det er dog faktisk default).

```
cor.test(???, ???, method="pearson")
```

- Hvad er korrelationen mellem `Girth` og `Volume`? Anvend de log-transformerede værdier til variabelen `Volume` inden du laver testen (dvs. brug `log()` funktionen).
- Hvad er p-værdien? Er den signifikant?

18) (ANOVA)

OBS! Hvis du føler dig usikker med funktionen `lm()` - der kommer en video om det i morgen (i forbindelse med emnet R Markdown).

- Kør følgende kode til at lave variansanalysen, der tester nulhypotesen hvor den gennemsnitlige værdi af variabelen `Sepal.Width` er ens for hver af de tre arter (variabelen `Species`) fra datasættet `iris`:

```
data(iris)


#model under H0: no difference according to group variable Species (1 just means "fit overall mean")
model_h0 <- lm(Sepal.Width ~ 1, data = iris)

#model under H1: each level of group variable Species has its own mean
model_h1 <- lm(Sepal.Width ~ Species, data = iris)

#compare two models - significant p-value equates to choosing H1 model
anova(model_h0, model_h1)
```

```
## Analysis of Variance Table
##
## Model 1: Sepal.Width ~ 1
## Model 2: Sepal.Width ~ Species
##   Res.Df    RSS Df Sum of Sq   F    Pr(>F)
## 1     149 28.307
## 2     147 16.962   2    11.345 49.16 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
#check assumptions for alternative model
par(mfrow = c(1,2))
plot(model_h1, which = c(1,2))
```



Kig på outputtet:

- Hvilken model reflekterer nulhypotesen?
- Hvilken model reflekterer alternativhypotesen?
- Hvor er p-værdien?
- Er der en signifikant forskel i den gennemsnitlige `Sepal.Width` efter de forskellige `Species`?
- Kan vi stole på testen (tjek forudsætninger til ANOVA).

19) (ANOVA)

Lav en lignende analyse på datasættet `chickwts` for at svare på spørgsmålet:

- Er der en forskel i den gennemsnitlige vægt (variablen `weight`) efter fodertypen (variablen `feed`)? Med andre ord, er vægt afhængig af fodertypen?

```
data(chickwts)
```

OBS! Hvis du er usikker med lineær regression: se venligst videoerne til emnet R Markdown og kom tilbage til følgende spørgsmål

20) (Lineær regression)

- Brug `lm` til at lave en simpel lineær regression så at variablen `Volume` (response) er afhængig af variablen `Girth` (datasættet `trees`).

```
mylm <- lm(???, data = trees)
```

Brug `summary` på din model for at finde følgende værdier:

- Hvad er `r.squared`? (multiple)
- Er variabelen `Girth` signifikant?
- Hvad er formelen på den bedste rette linje (husk formen $y = ax + b$)?

21) (Kort intro til multiple lineær regression)

Tag ovenstående model og tilføj variabelen `Height` som en ekstra prædikator (uafhængig) variabel i modellen med en “+” tegn:

```
mylm_height <- lm(??? ~ ??? + ???, data = rees)  
summary(mylm_height)
```

Bemærk at det ikke betyder, at de to variabler skal lægges sammen, men at vi vil have begge variabler i modellen som uafhængig variabler (med andre ord er `Volume` afhængig af både `Girth` og `Height`).

Benyt `summary` på modellen og prøv at finde følgende:

- Hvad er (multiple) `r.squared` værdien?
- Hvor meget ændrer (multiple) `r.squared` værdien sig i forhold til modellen med kun variabelen `Girth`?
- Er `Volume` signifikant afhængig af `Height` (efter at man har taget højde for `Girth`)?

Brug funktionen `anova` til at sammenligne modellen uden `Height` og modellen med `Height`.

```
anova(#model without height, #model with height)
```

Bemærk at i dette tilfælde er p-værdien fra ANOVA samme p-værdien fra `summary(mylm_height)`.